

Eingereicht von
Dipl.-Ing. **Philipp Schmidt**,
BSc

Angefertigt am
Institut

Betreuer
Prof. Dr.

19. April 2025

Überblick und Anwendung von Maschinellem Lernen im Kontext von Quantitativer Finanz



Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation und Relevanz	1
1.2	Forschungsziel und Fragestellungen	1
1.3	Methodik und Aufbau der Arbeit	2
2	Grundlagen der Quantitativen Finanzwissenschaft	3
2.1	Mathematische Modellierung in der Finanzwelt	3
2.2	Stochastische Prozesse und Finanzmathematik	3
2.3	Klassische Finanzmodelle	4
2.4	Herausforderungen klassischer Finanzmodelle	4
3	Reinforcement Learning in der Quantitativen Finanzwissenschaft .	5
3.1	Grundlagen des Reinforcement Learning	5
3.2	Value-Based und Policy-Based Methoden	6
3.3	Deep Reinforcement Learning und Finanzmärkte	7
3.4	Vergleich mit traditionellen Optimierungsmethoden	7
3.5	Kritische Betrachtung der Anwendbarkeit im Finanzsektor .	8
	Books	9
	Articles	10

1 Einleitung

Die zunehmende Automatisierung und Digitalisierung der Finanzmärkte hat den Einsatz von Reinforcement Learning (RL) als vielversprechende Methode zur Optimierung algorithmischer Handelsstrategien verstärkt. Insbesondere Multi-Agent Reinforcement Learning (MARL) hat sich als ein leistungsfähiges Konzept etabliert, um Handelsstrategien durch kooperative und kompetitive Interaktionen autonomer Agenten zu verbessern[2]. Durch den Einsatz moderner RL-Methoden lassen sich komplexe Marktstrukturen modellieren und adaptive Strategien entwickeln, die über traditionelle regelbasierte Ansätze hinausgehen[3].

1.1 Motivation und Problemstellung

Klassische Handelsstrategien basieren oft auf starren Regeln oder heuristischen Verfahren, die auf historische Daten kalibriert wurden. Diese Methoden stoßen an ihre Grenzen, wenn Marktbedingungen sich abrupt ändern oder unvorhersehbare Ereignisse auftreten. Reinforcement Learning ermöglicht es, Strategien kontinuierlich anzupassen, indem Agenten durch Interaktionen mit dem Marktumfeld lernen, optimale Entscheidungen zu treffen[4]. Dabei zeigt insbesondere Multi-Agent Reinforcement Learning vielversprechende Ansätze für den algorithmischen Handel und das Portfoliomanagement, da mehrere Agenten simultan agieren und sich gegenseitig beeinflussen[2].

1.2 Forschungsfrage und Zielsetzung

Diese Arbeit untersucht die Frage: *"Kann Multi-Agent Reinforcement Learning klassische Portfoliomanagement-Ansätze übertreffen?"*

Zur Beantwortung dieser Frage werden bestehende Methoden aus der Finanzmathematik mit modernen MARL-Ansätzen verglichen. Es wird analysiert, inwiefern RL-Strategien klassische Optimierungsmodelle wie das oder regelbasierte Handelsstrategien in Bezug auf Rendite und Risikomanagement übertreffen können.

1.3 Methodik und Aufbau der Arbeit

Zur Untersuchung dieser Fragestellung wird eine umfassende Literaturanalyse durchgeführt, die aktuelle Forschungsergebnisse zu MARL und Finanzmärkten systematisch bewertet. Dabei werden sowohl theoretische Grundlagen als auch empirische Studien betrachtet, um eine fundierte Einschätzung der Leistungsfähigkeit von MARL zu erhalten.

Die Arbeit gliedert sich wie folgt: Kapitel 2 behandelt die theoretischen Grundlagen von RL und MARL, einschließlich mathematischer Modelle und Algorithmen. In Kapitel ?? werden Anwendungsfälle von MARL in Finanzmärkten diskutiert. Kapitel ?? vergleicht klassische Finanzmodelle mit MARL-basierten Handelsstrategien. Anschließend werden in Kapitel ?? die Herausforderungen und Limitationen von MARL untersucht. Kapitel ?? fasst die Ergebnisse zusammen und gibt einen Ausblick auf zukünftige Entwicklungen.

2 Grundlagen der Quantitativen Finanzwissenschaft

Die quantitative Finanzwissenschaft befasst sich mit der Anwendung mathematischer und statistischer Methoden zur Modellierung und Analyse von Finanzmärkten. Ein wesentliches Ziel besteht darin, Marktbewegungen vorherzusagen, Risikomanagementstrategien zu optimieren und Handelsstrategien algorithmisch zu verbessern¹.

2.1 Mathematische Modellierung in der Finanzwelt

Mathematische Modelle spielen eine zentrale Rolle in der Finanzwissenschaft. Sie ermöglichen die formale Beschreibung von Preisbewegungen, Risikomaßen und Optimierungsproblemen. Ein klassisches Modell ist das Black-Scholes-Modell, das zur Bewertung von Optionen verwendet wird².

¹5.

²6.

2.2 Stochastische Prozesse und Finanzmathematik

Die Modellierung von Finanzmärkten erfordert den Einsatz stochastischer Prozesse, da Kursbewegungen von Unsicherheit und zufälligen Schwankungen geprägt sind. Wichtige Prozesse in diesem Zusammenhang sind:

Wiener-Prozesse und Brown'sche Bewegung

Die Brown'sche Bewegung, eingeführt durch [7], bildet die Grundlage vieler stochastischer Finanzmodelle. Der Wiener-Prozess W_t ist ein spezieller Fall und erfüllt die Eigenschaften:

$$W_t \sim \mathcal{N}(0, t) \quad (0.1)$$

Martingale und arbitragefreie Märkte

Ein Martingal ist ein stochastischer Prozess X_t , für den gilt:

$$\mathbb{E}[X_{t+1} \mid X_t, X_{t-1}, \dots] = X_t \quad (0.2)$$

Dies bedeutet, dass die beste Schätzung für den zukünftigen Wert eines Martingals sein aktueller Wert ist³. Martingale sind eng mit arbitragefreien Märkten verbunden, da unter der Martingal-Maß keine risikolosen Arbitragemöglichkeiten existieren.

³8.

2.3 Klassische Finanzmodelle

Einige der bekanntesten Modelle in der Finanzmathematik sind:

- **Black-Scholes-Merton-Modell:** Zur Bewertung von Optionen unter der Annahme von stochastischer Volatilität⁴.
- **Heston-Modell:** Eine Erweiterung des Black-Scholes-Modells, das eine zufällig schwankende Volatilität berücksichtigt⁵.
- **Markowitz-Portfolio-Theorie:** Ein fundamentales Modell zur Portfolio-Optimierung basierend auf Erwartungswerten und Kovarianzen von Wertpapieren⁶.

2.4 Herausforderungen klassischer Finanzmodelle

Klassische Finanzmodelle stoßen in realen Märkten an ihre Grenzen. Sie beruhen oft auf Annahmen wie der Normalverteilung von Renditen oder der Existenz eines risikofreien Zinssatzes. In der Praxis zeigen sich jedoch:

- **Fette Ränder in Renditeverteilungen:** Extremwerte treten häufiger auf als in der Normalverteilung.
- **Mangelnde Berücksichtigung von Marktstrukturen:** Mikrostrukturen des Marktes wie Liquiditätsengpässe oder algorithmischer Handel werden oft nicht berücksichtigt.
- **Nichtstationarität der Finanzzeitreihen:** Finanzmärkte sind dynamisch, so dass Modelle kontinuierlich angepasst werden müssen.

⁴6.

⁵9.

⁶Markowitz1952.

3 Reinforcement Learning in der Quantitativen Finanzwissenschaft

Die Anwendung von Reinforcement Learning in den Finanzmärkten hat in den letzten Jahren erhebliche Fortschritte gemacht. Aufgrund der stochastischen Natur der Märkte, der hohen Dimensionalität von Handelsstrategien und der Notwendigkeit adaptiver Entscheidungsfindung ist RL eine vielversprechende Methode zur Optimierung algorithmischer Handelsstrategien und Portfoliomanagement-Techniken⁷.

3.1 Grundlagen des Reinforcement Learning

Das Konzept von Reinforcement Learning basiert auf einem Agenten, der in einer Umgebung agiert und durch Belohnungen lernt, welche Handlungen optimal sind. Formell wird dies durch einen Markov-Entscheidungsprozess (MDP) beschrieben, der aus einem Tupel (S, A, P, R, γ) besteht:

- S - die Menge der möglichen Zustände der Umwelt,
- A - die Menge der möglichen Aktionen des Agenten,
- $P(s'|s, a)$ - die Übergangswahrscheinlichkeit vom Zustand s zu s' nach Aktion a ,
- $R(s, a)$ - die erhaltene Belohnung nach Ausführen der Aktion a in Zustand s ,
- $\gamma \in [0, 1]$ - der Diskontierungsfaktor, der zukünftige Belohnungen gewichtet.

Das Ziel des Agenten ist es, eine optimale Policy $\pi(a|s)$ zu finden, die den erwarteten kumulierten Nutzen maximiert:

$$V^\pi(s) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s \right]. \quad (0.3)$$

⁷10, 11.

3.2 Value-Based und Policy-Based Methoden

Innerhalb des RL gibt es zwei Hauptansätze zur Optimierung der Entscheidungsstrategie:

Value-Based Methoden

Hierbei wird die sogenannte **Q-Funktion** geschätzt, die den erwarteten Nutzen eines Zustands-Aktions-Paares beschreibt:

$$Q(s, a) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s, a_0 = a \right]. \quad (0.4)$$

Zu den bekanntesten Methoden gehören:

- **Q-Learning**: Eine tabellarische Methode zur iterativen Approximation der Q-Werte⁸.
- **Deep Q-Networks (DQN)**: Erweiterung von Q-Learning durch neuronale Netze zur Approximation von Q-Werten bei hochdimensionalen Zustandsräumen⁹.

Policy-Based Methoden

Policy-Gradient-Methoden optimieren direkt die Policy $\pi(a|s)$, anstatt Wertefunktionen zu approximieren. Wichtige Algorithmen sind:

- **REINFORCE**: Ein einfacher Policy-Gradient-Ansatz, der die Strategie direkt aktualisiert¹⁰.
- **Actor-Critic-Methoden**: Kombination aus Policy-Optimierung und Wertfunktion-Schätzung zur Stabilisierung des Lernprozesses¹¹.

⁸12.

⁹13.

¹⁰Williams1992.

¹¹Sutton2000.

3.3 Deep Reinforcement Learning und Finanzmärkte

Durch den Einsatz neuronaler Netze hat sich **Deep Reinforcement Learning (DRL)** als leistungsfähige Technik zur Modellierung von Finanzmärkten etabliert. Insbesondere in Handelsstrategien, Portfoliomanagement und Market Making wurden DRL-Methoden erfolgreich angewendet¹².

Zu den prominenten DRL-Ansätzen gehören:

- **Deep Deterministic Policy Gradient (DDPG)**: Ermöglicht kontinuierliche Aktionsräume für quantitative Strategien¹³.
- **Proximal Policy Optimization (PPO)**: Verbessert die Stabilität und Effizienz des Lernprozesses im Vergleich zu traditionellen Policy-Gradient-Methoden¹⁴.

3.4 Vergleich mit traditionellen Optimierungsmethoden

Traditionelle Finanzmodelle basieren oft auf **heuristischen oder regelbasierten Strategien**, die nicht adaptiv auf sich ändernde Marktbedingungen reagieren. RL-Ansätze bieten im Vergleich dazu folgende Vorteile:

- **Anpassungsfähigkeit**: RL kann sich an veränderte Marktbedingungen anpassen, während klassische Modelle oft eine stationäre Umgebung voraussetzen.
- **Automatisierte Entscheidungsfindung**: RL-Algorithmen optimieren Strategien direkt aus historischen und simulierten Marktdaten.
- **Generalität**: RL kann auf verschiedene Handelsstrategien angewendet werden, von Market Making bis hin zu Risikomanagement¹⁵.

¹²Dixon2020, 3.

¹³Lillicrap2016.

¹⁴14.

¹⁵Fischer2018.

3.5 Kritische Betrachtung der Anwendbarkeit im Finanzsektor

Trotz der Fortschritte von RL gibt es mehrere Herausforderungen für den praktischen Einsatz im Finanzsektor:

- **Overfitting:** RL-Modelle können an vergangene Marktdaten überangepasst sein und schlecht auf neue Marktsituationen generalisieren.
- **Datenqualität und Verfügbarkeit:** Historische Daten sind oft begrenzt oder durch **Survivorship Bias** beeinflusst.
- **Regulatorische Unsicherheiten:** Der Einsatz von KI-basierten Algorithmen im Finanzhandel unterliegt zunehmend regulatorischen Beschränkungen¹⁶.

¹⁶Alderman2021.

Books

- [1] Richard S. Sutton und Andrew G. Barto.
Reinforcement Learning: An Introduction. 2. Aufl. MIT Press, 2018.
DOI: 10.5555/3312046.
URL: <https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf> (siehe S. 1).
- [5] Steven E. Shreve.
Stochastic Calculus for Finance II: Continuous-Time Models. Springer, 2004.
DOI: 10.1007/978-0-387-40101-3.
URL: <https://doi.org/10.1007/978-0-387-40101-3> (siehe S. 3).
- [8] Hans Föllmer und Alexander Schied.
Stochastic Finance: An Introduction in Discrete Time. 4. Aufl. de Gruyter, 2016.
DOI: 10.1515/9783110463469.
URL: <https://doi.org/10.1515/9783110463469> (siehe S. 4).

Articles

- [2] Ryan Lowe u. a.
Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments.
 Advances in Neural Information Processing Systems (NeurIPS) Volume: 30
 (2017).
 DOI: 10.48550/arXiv.1706.02275.
 URL: <https://arxiv.org/abs/1706.02275> (siehe S. 1).

- [3] H. Zhang u. a.
Strategic Trading in Quantitative Markets Through Multi-Agent Reinforcement Learning.
 arXiv preprint (2023).
 DOI: 10.48550/arXiv.2303.11959.
 URL: <https://arxiv.org/abs/2303.11959> (siehe S. 1, 7).

- [4] A. Thakkar und K. Chaudhari.
A Comprehensive Survey on Deep Neural Networks for Stock Market: The Need, Challenges, and Future Directions.
 Expert Systems with Applications Volume: 177 (2021), Pages: 114800.
 DOI: 10.1016/j.eswa.2021.114800.
 URL: <https://doi.org/10.1016/j.eswa.2021.114800> (siehe S. 1).

- [6] Fischer Black und Myron Scholes.
The Pricing of Options and Corporate Liabilities.
 Journal of Political Economy Volume: 81 (1973), Pages: 637–654.
 DOI: 10.1086/260062.
 URL: <https://www.jstor.org/stable/1831029> (siehe S. 3, 4).

- [7] Louis Bachelier.
Théorie de la spéculation.
 Annales scientifiques de l'École Normale Supérieure Volume: 17 (1900), Pages: 21–86.
 DOI: 10.24033/asens.476.
 URL: <https://doi.org/10.24033/asens.476> (siehe S. 3).

- [9] Steven L. Heston.
A Closed-Form Solution for Options with Stochastic Volatility.
 The Review of Financial Studies Volume: 6 (1993), Pages: 327–343.
 DOI: 10.1093/rfs/6.2.327.
 URL: <https://doi.org/10.1093/rfs/6.2.327> (siehe S. 4).

- [10] John Moody und Matthew Saffell.
Reinforcement Learning for Trading Systems and Portfolios.
 Proceedings of the IEEE/IAFE Conference on Computational Intelligence
 for Financial Engineering (1998), Pages: 32–38.
 DOI: 10.1109/CIFER.1998.683464 (siehe S. 5).

- [11] M. Dempster und V. Leemans.
An Automated FX Trading System Using Adaptive Reinforcement Learning.
 Expert Systems with Applications Volume: 30 (2006), Pages: 543–552.
 DOI: 10.1016/j.eswa.2005.10.002.
 URL: <https://doi.org/10.1016/j.eswa.2005.10.002> (siehe S. 5).

- [12] C. J. C. H. Watkins und Peter Dayan.
Q-Learning.
 Machine Learning Volume: 8 (1992), Pages: 279–292.
 DOI: 10.1007/BF00992698 (siehe S. 6).

- [13] Volodymyr Mnih et al.
Human-Level Control Through Deep Reinforcement Learning.
 Nature Volume: 518 (2015), Pages: 529–533.
 DOI: 10.1038/nature14236.
 URL: <https://doi.org/10.1038/nature14236> (siehe S. 6).

- [14] John Schulman et al.
Proximal Policy Optimization Algorithms.
 arXiv preprint (2017).
 DOI: 10.48550/arXiv.1707.06347.
 URL: <https://arxiv.org/abs/1707.06347> (siehe S. 7).