

Eingereicht von
Dipl.-Ing. **Philipp Schmidt**,
BSc

Angefertigt am
Institut

Betreuer
Prof. Dr.

16. März 2025

Überblick und Anwendung von Maschinellem Lernen im Kontext von Quantitativer Finanz



Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation und Relevanz	1
1.2	Forschungsziel und Fragestellungen	1
1.3	Methodik und Aufbau der Arbeit	2
2	Grundlagen der Quantitativen Finanzwissenschaft	3
2.1	Mathematische Modellierung in der Finanzwelt	3
2.2	Stochastische Prozesse und Finanzmathematik	3
2.3	Klassische Finanzmodelle	4
2.4	Herausforderungen klassischer Finanzmodelle	4
3	Reinforcement Learning in der Quantitativen Finanzwissenschaft .	5
3.1	Grundlagen des Reinforcement Learning	5
3.2	Value-Based und Policy-Based Methoden	6
3.3	Deep Reinforcement Learning und Finanzmärkte	7
3.4	Vergleich mit traditionellen Optimierungsmethoden	7
3.5	Kritische Betrachtung der Anwendbarkeit im Finanzsektor .	8
	Books	9
	Articles	10

1 Einleitung

Die fortschreitende Digitalisierung der Finanzmärkte hat in den vergangenen Jahren zu einem verstärkten Einsatz von Machine Learning-basierten Algorithmen geführt. Insbesondere Reinforcement Learning (RL) hat sich als vielversprechende Methode zur Optimierung von Handelsstrategien und zur Bewältigung der zunehmenden Komplexität und Volatilität von Finanzmärkten etabliert¹. Während herkömmliche Handelsmodelle oft auf heuristischen oder regelbasierten Ansätzen beruhen, bietet RL die Möglichkeit, Entscheidungen adaptiv und datengetrieben zu optimieren.

Eine spezielle Unterkategorie ist das Multi-Agent Reinforcement Learning (MARL), bei dem mehrere Agenten simultan in einer gemeinsamen Umgebung agieren und ihre Strategien unter Berücksichtigung der Interaktionen mit anderen Marktteilnehmern anpassen². Dieser Ansatz ermöglicht die Modellierung realistischer Marktdynamiken, insbesondere in Kontexten wie Market Making, Hochfrequenzhandel und algorithmischem Portfoliomanagement³.

1.1 Motivation und Relevanz

Die zunehmende Automatisierung des Handels und die wachsende Verfügbarkeit von Marktdaten haben neue Möglichkeiten für den Einsatz von MARL in der Finanzwelt eröffnet. Insbesondere die Fähigkeit von MARL, komplexe Strategien autonom zu erlernen und auf sich verändernde Marktbedingungen zu reagieren, macht es zu einem vielversprechenden Werkzeug für institutionelle Investoren und algorithmische Handelsfirmen⁴. Dennoch gibt es zahlreiche Herausforderungen, darunter die Stabilität der Lernprozesse, die Interpretierbarkeit der Modelle sowie regulatorische und ethische Fragestellungen.

1.2 Forschungsziel und Fragestellungen

Diese Arbeit untersucht den aktuellen Stand der Forschung zu MARL im Finanzsektor und analysiert, inwieweit bestehende Ansätze herkömmliche Handelsstra-

¹.

².

³.

⁴.

tegien übertreffen können. Dabei werden insbesondere folgende Forschungsfragen adressiert:

- Welche Vorteile bietet MARL gegenüber traditionellen Handelsalgorithmen?
- Wie stabil sind MARL-basierte Strategien unter realen Marktbedingungen?
- Welche Herausforderungen ergeben sich bei der praktischen Implementierung von MARL im Finanzhandel?

1.3 Methodik und Aufbau der Arbeit

Diese Arbeit basiert auf einer systematischen Literaturanalyse aktueller Forschungsergebnisse im Bereich MARL und Finanzmärkte. Zunächst werden die theoretischen Grundlagen von Reinforcement Learning und Multi-Agent Reinforcement Learning erläutert. Anschließend werden relevante wissenschaftliche Beiträge analysiert und hinsichtlich ihrer Effektivität, Skalierbarkeit und praktischen Anwendbarkeit bewertet. Abschließend erfolgt eine kritische Diskussion der offenen Herausforderungen und zukünftiger Forschungsperspektiven.

Der weitere Aufbau dieser Arbeit gliedert sich wie folgt:

- Kapitel 2 beschreibt die mathematischen und theoretischen Grundlagen von RL und MARL.
- Kapitel ?? diskutiert konkrete Anwendungsfälle von MARL im Finanzsektor.
- Kapitel ?? enthält eine kritische Betrachtung der bisherigen Forschungsergebnisse und identifiziert offene Herausforderungen.
- Kapitel ?? fasst die wichtigsten Erkenntnisse zusammen und gibt einen Ausblick auf zukünftige Forschung.

2 Grundlagen der Quantitativen Finanzwissenschaft

Die quantitative Finanzwissenschaft befasst sich mit der Anwendung mathematischer und statistischer Methoden zur Modellierung und Analyse von Finanzmärkten. Ein wesentliches Ziel besteht darin, Marktbewegungen vorherzusagen, Risikomanagementstrategien zu optimieren und Handelsstrategien algorithmisch zu verbessern⁵.

2.1 Mathematische Modellierung in der Finanzwelt

Mathematische Modelle spielen eine zentrale Rolle in der Finanzwissenschaft. Sie ermöglichen die formale Beschreibung von Preisbewegungen, Risikomaßen und Optimierungsproblemen. Ein klassisches Modell ist das Black-Scholes-Modell, das zur Bewertung von Optionen verwendet wird⁶.

2.2 Stochastische Prozesse und Finanzmathematik

Die Modellierung von Finanzmärkten erfordert den Einsatz stochastischer Prozesse, da Kursbewegungen von Unsicherheit und zufälligen Schwankungen geprägt sind. Wichtige Prozesse in diesem Zusammenhang sind:

Wiener-Prozesse und Brown'sche Bewegung

Die Brown'sche Bewegung, eingeführt durch [7], bildet die Grundlage vieler stochastischer Finanzmodelle. Der Wiener-Prozess W_t ist ein spezieller Fall und erfüllt die Eigenschaften:

$$W_t \sim \mathcal{N}(0, t) \tag{0.1}$$

⁵5.

⁶6.

Martingale und arbitragefreie Märkte

Ein Martingal ist ein stochastischer Prozess X_t , für den gilt:

$$\mathbb{E}[X_{t+1} \mid X_t, X_{t-1}, \dots] = X_t \quad (0.2)$$

Dies bedeutet, dass die beste Schätzung für den zukünftigen Wert eines Martingals sein aktueller Wert ist⁷. Martingale sind eng mit arbitragefreien Märkten verbunden, da unter der Martingal-Maß keine risikolosen Arbitragemöglichkeiten existieren.

2.3 Klassische Finanzmodelle

Einige der bekanntesten Modelle in der Finanzmathematik sind:

- **Black-Scholes-Merton-Modell:** Zur Bewertung von Optionen unter der Annahme von stochastischer Volatilität⁸.
- **Heston-Modell:** Eine Erweiterung des Black-Scholes-Modells, das eine zufällig schwankende Volatilität berücksichtigt⁹.
- **Markowitz-Portfolio-Theorie:** Ein fundamentales Modell zur Portfolio-Optimierung basierend auf Erwartungswerten und Kovarianzen von Wertpapieren¹⁰.

2.4 Herausforderungen klassischer Finanzmodelle

Klassische Finanzmodelle stoßen in realen Märkten an ihre Grenzen. Sie beruhen oft auf Annahmen wie der Normalverteilung von Renditen oder der Existenz eines risikofreien Zinssatzes. In der Praxis zeigen sich jedoch:

⁷8.

⁸6.

⁹9.

¹⁰Markowitz1952.

- **Fette Ränder in Renditeverteilungen:** Extremwerte treten häufiger auf als in der Normalverteilung.
- **Mangelnde Berücksichtigung von Marktstrukturen:** Mikrostrukturen des Marktes wie Liquiditätsengpässe oder algorithmischer Handel werden oft nicht berücksichtigt.
- **Nichtstationarität der Finanzzeitreihen:** Finanzmärkte sind dynamisch, so dass Modelle kontinuierlich angepasst werden müssen.

3 Reinforcement Learning in der Quantitativen Finanzwissenschaft

Die Anwendung von Reinforcement Learning in den Finanzmärkten hat in den letzten Jahren erhebliche Fortschritte gemacht. Aufgrund der stochastischen Natur der Märkte, der hohen Dimensionalität von Handelsstrategien und der Notwendigkeit adaptiver Entscheidungsfindung ist RL eine vielversprechende Methode zur Optimierung algorithmischer Handelsstrategien und Portfoliomanagement-Techniken¹¹.

3.1 Grundlagen des Reinforcement Learning

Das Konzept von Reinforcement Learning basiert auf einem Agenten, der in einer Umgebung agiert und durch Belohnungen lernt, welche Handlungen optimal sind. Formell wird dies durch einen Markov-Entscheidungsprozess (MDP) beschrieben, der aus einem Tupel (S, A, P, R, γ) besteht:

- S - die Menge der möglichen Zustände der Umwelt,
- A - die Menge der möglichen Aktionen des Agenten,
- $P(s'|s, a)$ - die Übergangswahrscheinlichkeit vom Zustand s zu s' nach Aktion a ,

¹¹10, 11.

- $R(s, a)$ - die erhaltene Belohnung nach Ausführen der Aktion a in Zustand s ,
- $\gamma \in [0, 1]$ - der Diskontierungsfaktor, der zukünftige Belohnungen gewichtet.

Das Ziel des Agenten ist es, eine optimale Policy $\pi(a|s)$ zu finden, die den erwarteten kumulierten Nutzen maximiert:

$$V^\pi(s) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s \right]. \quad (0.3)$$

3.2 Value-Based und Policy-Based Methoden

Innerhalb des RL gibt es zwei Hauptansätze zur Optimierung der Entscheidungsstrategie:

Value-Based Methoden

Hierbei wird die sogenannte **Q-Funktion** geschätzt, die den erwarteten Nutzen eines Zustands-Aktions-Paares beschreibt:

$$Q(s, a) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s, a_0 = a \right]. \quad (0.4)$$

Zu den bekanntesten Methoden gehören:

- **Q-Learning**: Eine tabellarische Methode zur iterativen Approximation der Q-Werte¹².
- **Deep Q-Networks (DQN)**: Erweiterung von Q-Learning durch neuronale Netze zur Approximation von Q-Werten bei hochdimensionalen Zustandsräumen¹³.

¹²12.

¹³13.

Policy-Based Methoden

Policy-Gradient-Methoden optimieren direkt die Policy $\pi(a|s)$, anstatt Wertefunktionen zu approximieren. Wichtige Algorithmen sind:

- **REINFORCE**: Ein einfacher Policy-Gradient-Ansatz, der die Strategie direkt aktualisiert¹⁴.
- **Actor-Critic-Methoden**: Kombination aus Policy-Optimierung und Wertfunktion-Schätzung zur Stabilisierung des Lernprozesses¹⁵.

3.3 Deep Reinforcement Learning und Finanzmärkte

Durch den Einsatz neuronaler Netze hat sich **Deep Reinforcement Learning (DRL)** als leistungsfähige Technik zur Modellierung von Finanzmärkten etabliert. Insbesondere in Handelsstrategien, Portfoliomanagement und Market Making wurden DRL-Methoden erfolgreich angewendet¹⁶.

Zu den prominenten DRL-Ansätzen gehören:

- **Deep Deterministic Policy Gradient (DDPG)**: Ermöglicht kontinuierliche Aktionsräume für quantitative Strategien¹⁷.
- **Proximal Policy Optimization (PPO)**: Verbessert die Stabilität und Effizienz des Lernprozesses im Vergleich zu traditionellen Policy-Gradient-Methoden¹⁸.

3.4 Vergleich mit traditionellen Optimierungsmethoden

Traditionelle Finanzmodelle basieren oft auf **heuristischen oder regelbasierten Strategien**, die nicht adaptiv auf sich ändernde Marktbedingungen reagieren. RL-Ansätze bieten im Vergleich dazu folgende Vorteile:

¹⁴Williams1992.

¹⁵Sutton2000.

¹⁶Dixon2020, 3.

¹⁷Lillicrap2016.

¹⁸14.

- **Anpassungsfähigkeit:** RL kann sich an veränderte Marktbedingungen anpassen, während klassische Modelle oft eine stationäre Umgebung voraussetzen.
- **Automatisierte Entscheidungsfindung:** RL-Algorithmen optimieren Strategien direkt aus historischen und simulierten Marktdaten.
- **Generalität:** RL kann auf verschiedene Handelsstrategien angewendet werden, von Market Making bis hin zu Risikomanagement¹⁹.

3.5 Kritische Betrachtung der Anwendbarkeit im Finanzsektor

Trotz der Fortschritte von RL gibt es mehrere Herausforderungen für den praktischen Einsatz im Finanzsektor:

- **Overfitting:** RL-Modelle können an vergangene Marktdaten überangepasst sein und schlecht auf neue Marktsituationen generalisieren.
- **Datenqualität und Verfügbarkeit:** Historische Daten sind oft begrenzt oder durch ****Survivorship Bias**** beeinflusst.
- **Regulatorische Unsicherheiten:** Der Einsatz von KI-basierten Algorithmen im Finanzhandel unterliegt zunehmend regulatorischen Beschränkungen²⁰.

¹⁹Fischer2018.

²⁰Alderman2021.

Books

- [1] Richard S. Sutton und Andrew G. Barto.
Reinforcement Learning: An Introduction. 2. Aufl. MIT Press, 2018.
DOI: 10.5555/3312046.
URL: [https : / / web . stanford . edu / class / psych209 / Readings / SuttonBartoIPRLBook2ndEd.pdf](https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf) (siehe S. 1).
- [5] Steven E. Shreve.
Stochastic Calculus for Finance II: Continuous-Time Models. Springer, 2004.
DOI: 10.1007/978-0-387-40101-3.
URL: <https://doi.org/10.1007/978-0-387-40101-3> (siehe S. 3).
- [8] Hans Föllmer und Alexander Schied.
Stochastic Finance: An Introduction in Discrete Time. 4. Aufl. de Gruyter, 2016.
DOI: 10.1515/9783110463469.
URL: <https://doi.org/10.1515/9783110463469> (siehe S. 4).

Articles

- [2] Ryan Lowe u. a.
Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments.
Advances in Neural Information Processing Systems (NeurIPS) Volume: 30 (2017).
DOI: 10.48550/arXiv.1706.02275.
URL: <https://arxiv.org/abs/1706.02275> (siehe S. 1).
- [3] H. Zhang u. a.
Strategic Trading in Quantitative Markets Through Multi-Agent Reinforcement Learning.
arXiv preprint (2023).
DOI: 10.48550/arXiv.2303.11959.
URL: <https://arxiv.org/abs/2303.11959> (siehe S. 1, 7).
- [4] A. Thakkar und K. Chaudhari.
A Comprehensive Survey on Deep Neural Networks for Stock Market: The Need, Challenges, and Future Directions.
Expert Systems with Applications Volume: 177 (2021), Pages: 114800.
DOI: 10.1016/j.eswa.2021.114800.
URL: <https://doi.org/10.1016/j.eswa.2021.114800> (siehe S. 1).
- [6] Fischer Black und Myron Scholes.
The Pricing of Options and Corporate Liabilities.
Journal of Political Economy Volume: 81 (1973), Pages: 637–654.
DOI: 10.1086/260062.
URL: <https://www.jstor.org/stable/1831029> (siehe S. 3, 4).
- [7] Louis Bachelier.
Théorie de la spéculation.
Annales scientifiques de l'École Normale Supérieure Volume: 17 (1900), Pages: 21–86.
DOI: 10.24033/asens.476.
URL: <https://doi.org/10.24033/asens.476> (siehe S. 3).

- [9] Steven L. Heston.
A Closed-Form Solution for Options with Stochastic Volatility.
 The Review of Financial Studies Volume: 6 (1993), Pages: 327–343.
 DOI: 10.1093/rfs/6.2.327.
 URL: <https://doi.org/10.1093/rfs/6.2.327> (siehe S. 4).

- [10] John Moody und Matthew Saffell.
Reinforcement Learning for Trading Systems and Portfolios.
 Proceedings of the IEEE/IAFE Conference on Computational Intelligence
 for Financial Engineering (1998), Pages: 32–38.
 DOI: 10.1109/CIFER.1998.683464 (siehe S. 5).

- [11] M. Dempster und V. Leemans.
An Automated FX Trading System Using Adaptive Reinforcement Learning.
 Expert Systems with Applications Volume: 30 (2006), Pages: 543–552.
 DOI: 10.1016/j.eswa.2005.10.002.
 URL: <https://doi.org/10.1016/j.eswa.2005.10.002> (siehe S. 5).

- [12] C. J. C. H. Watkins und Peter Dayan.
Q-Learning.
 Machine Learning Volume: 8 (1992), Pages: 279–292.
 DOI: 10.1007/BF00992698 (siehe S. 6).

- [13] Volodymyr Mnih et al.
Human-Level Control Through Deep Reinforcement Learning.
 Nature Volume: 518 (2015), Pages: 529–533.
 DOI: 10.1038/nature14236.
 URL: <https://doi.org/10.1038/nature14236> (siehe S. 6).

- [14] John Schulman et al.
Proximal Policy Optimization Algorithms.
 arXiv preprint (2017).
 DOI: 10.48550/arXiv.1707.06347.
 URL: <https://arxiv.org/abs/1707.06347> (siehe S. 7).